# Árvores de Decisão

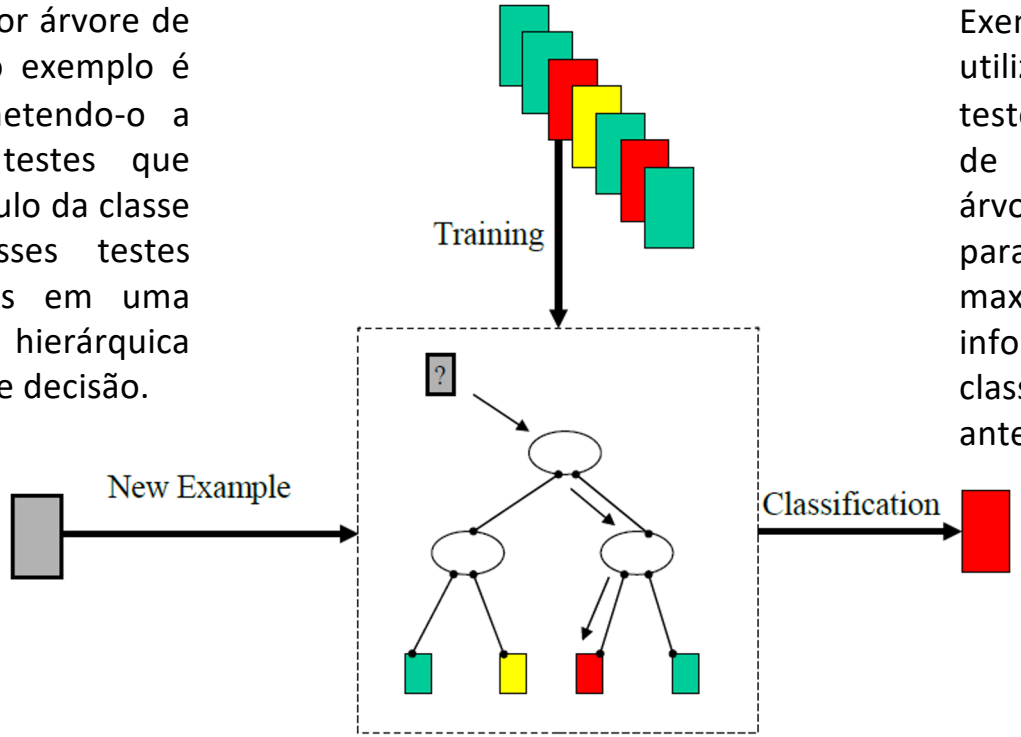
Sistemas Inteligentes

# Árvores de Decisão

- A árvore de decisão usa a estratégia “dividir para conquistar” para resolver problemas de decisão.
- Portanto, ela divide um problema complexo em problemas mais simples, aos quais recursivamente é aplicada a mesma estratégia.
- As soluções dos subproblemas podem ser combinadas, na forma de uma árvore, para produzir uma solução do problema complexo.
- Formalmente, uma árvore de decisão é um grafo acíclico direcionado em que cada nó ou é um nó de decisão ou um nó folha.

# Método de Aprendizado

No aprendizado por árvore de decisão, um novo exemplo é classificado submetendo-o a uma série de testes que determinam o rótulo da classe do exemplo. Esses testes estão organizados em uma estrutura hierárquica chamada árvore de decisão.




Exemplos de treinamento são utilizados para a escolha dos testes apropriados na árvore de decisão. Tipicamente, a árvore é construída de cima para baixo, onde os testes que maximizam o ganho de informação sobre a classificação são selecionados antes.

# Problema de Classificação

- Baseado nos seguintes dados:

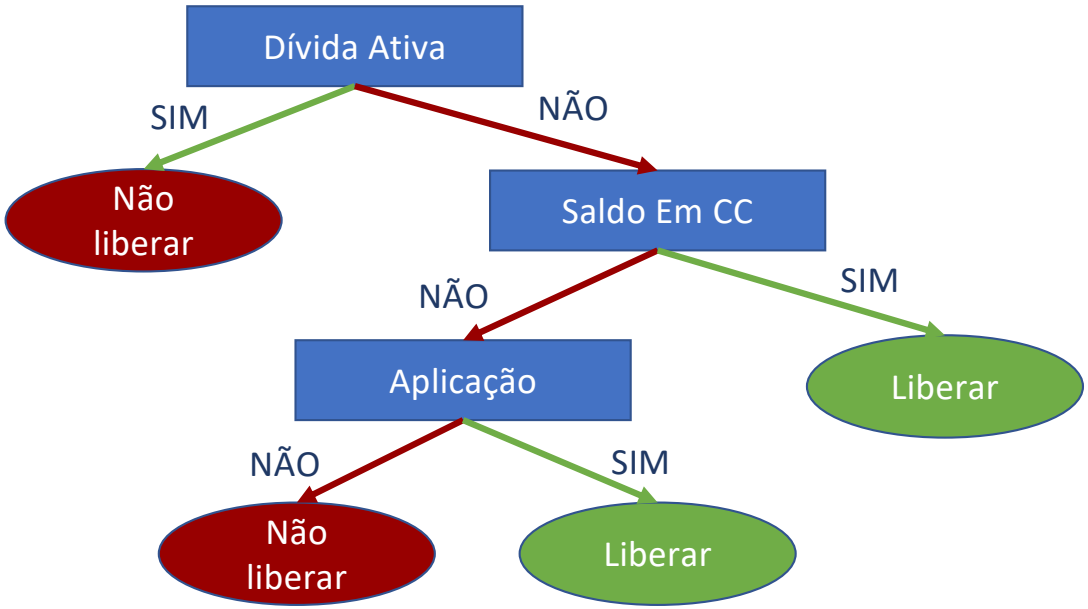
| Instância | Dívida Ativa | Saldo em CC | Aplicações | Crédito? |
|---|---|---|---|---|
| T1 | Sim | Não | Sim | Não liberar |
| T2 | Não | Não | Sim | Liberar |
| T3 | Não | Sim | Não | Liberar |
| T4 | Não | Não | Não | Não liberar |
| T5 | Sim | Sim | Não | Não liberar |
| T6 | Não | Não | Não | Não liberar |
| T7 | Não | Sim | Sim | Liberar |
| T8 | Sim | Não | Não | Não liberar |

- Qual seria a avaliação de crédito para essas novas pessoas?

| Instância | Dívida Ativa | Saldo em CC | Aplicações | Crédito? |
|---|---|---|---|---|
| T9 | Não | Sim | Sim | ? |
| T10 | Sim | Sim | Sim | ? |

# Árvores de Decisão

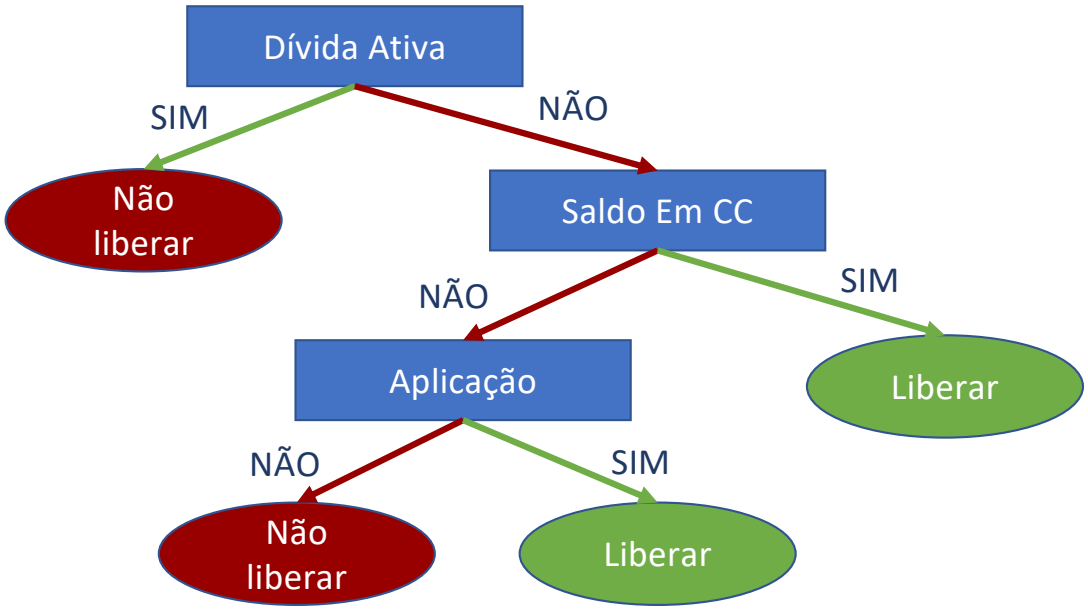
- Nós/Vértices: Testam o valor de um atributo
- Arestas: Correspondem ao resultado do teste (liga um nó a outro nó ou folha)
- Folhas: Terminais que indicam o resultado




Exemplo de árvore de decisão para avaliação de crédito

# Interpretação

1. Inicia no nó Raiz
2. Realiza o teste
3. Descende pelo vértice correspondente ao resultado
4. Vá ao passo 2 se não for uma folha
5. Predição gerada

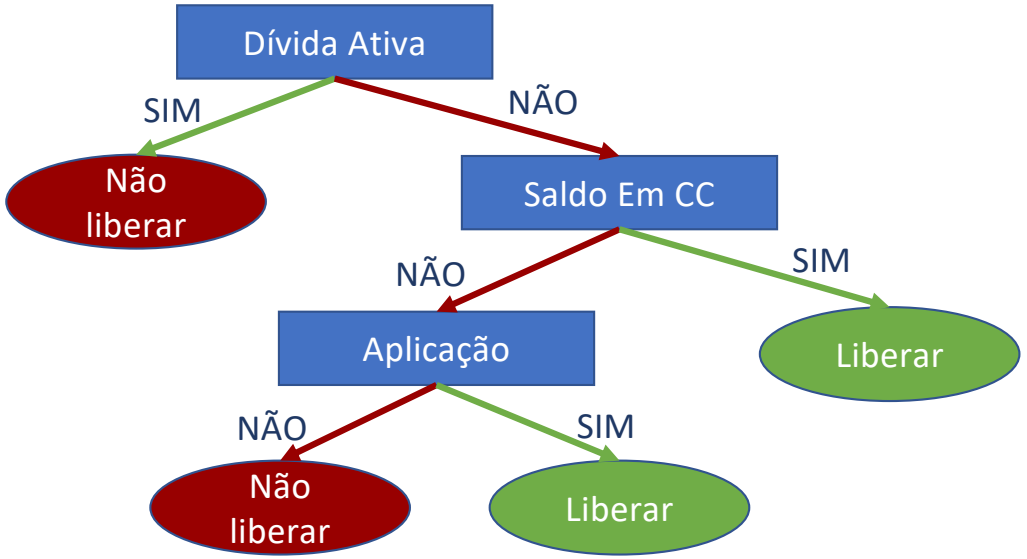



Exemplo de árvore de decisão para avaliação de crédito

# Problema de Classificação

- Qual seria a avaliação de crédito para essas novas pessoas?

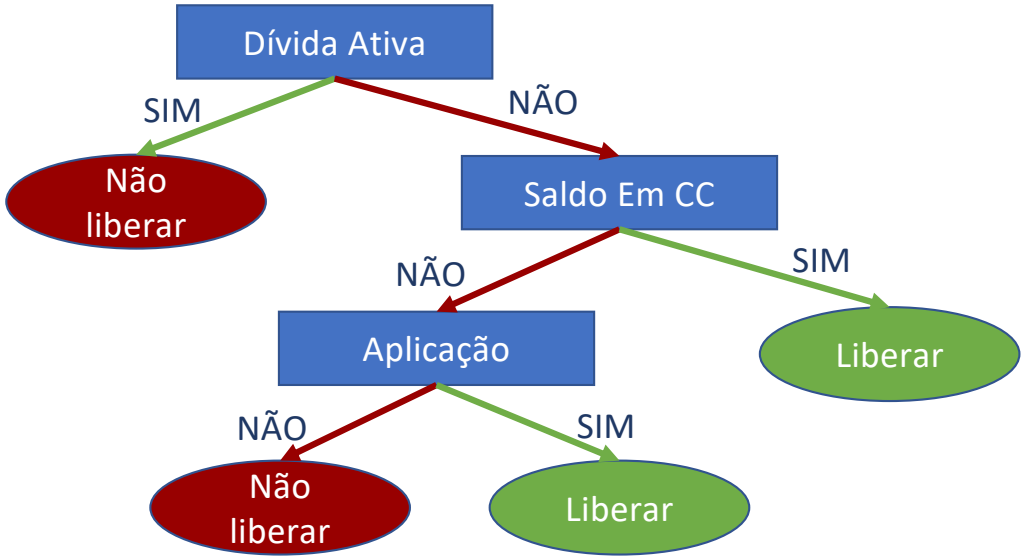
| Instância | Dívida Ativa | Saldo em CC | Aplicações | Crédito? |
|---|---|---|---|---|
| T9 | Sim | Sim | Sim | ? |
| T10 | Não | Sim | Sim | ? |



# Problema de Classificação

- Qual seria a avaliação de crédito para essas novas pessoas?

| Instância | Dívida Ativa | Saldo em CC | Aplicações | Crédito? |
|---|---|---|---|---|
| T9 | Sim | Sim | Sim | Não liberar |
| T10 | Não | Sim | Sim | Liberar |



# Algoritmo de Indução

**TDIDT: *Top-Down Induction of Decision Trees***

**Algoritmo ID3**

**Entrada: Conjunto de dados *S***

**Saída: Árvore de decisão**

**Se todas as instâncias em *S* pertencem à mesma classe *c***
**Retorna folha com o rótulo *c***
**Senão**

**Selecione um atributo *A* para realizar a divisão**

**Cria um novo nó *Ni* com o teste para *A***
**Para cada possível valor *vi* de *A***

**Crie novo conjunto de dados *Si* com todos os dado em *S* com *A=vi***

**Recursivamente crie uma árvore *Ti* com o conjunto de dados *Si***

**Conecte *Ti* a *Ni* por meio de uma aresta**
**Retorna o nó *Ni***

# Algoritmo de Indução

Dívida Ativa

| Instância | Dívida Ativa | Saldo em CC | Aplicações | Crédito? |
|---|---|---|---|---|
| T1 | Sim | Não | Sim | Não |
| T2 | Não | Não | Sim | Sim |
| T3 | Não | Sim | Não | Sim |
| T4 | Não | Não | Não | Não |
| T5 | Sim | Sim | Não | Não |
| T6 | Não | Não | Não | Não |
| T7 | Não | Sim | Sim | Sim |
| T8 | Sim | Não | Não | Não |

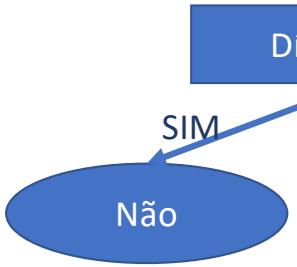
# Algoritmo de Indução




| Instância | Dívida Ativa | Saldo em CC | Aplicações | Crédito? |
|---|---|---|---|---|
| T1 | Sim | Não | Sim | Não |
| T5 | Sim | Sim | Não | Não |
| T8 | Sim | Não | Não | Não |

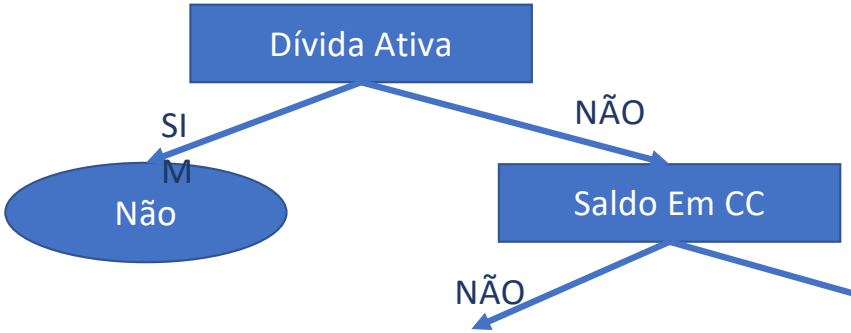
| Instância | Dívida Ativa | Saldo em CC | Aplicações | Crédito? |
|---|---|---|---|---|
| T2 | Não | Não | Sim | Sim |
| T3 | Não | Sim | Não | Sim |
| T4 | Não | Não | Não | Não |
| T6 | Não | Não | Não | Não |
| T7 | Não | Sim | Sim | Sim |

# Algoritmo de Indução




| Instância | Dívida Ativa | Saldo em CC | Aplicações | Crédito? |
|---|---|---|---|---|
| T2 | Não | Não | Sim | Sim |
| T3 | Não | Sim | Não | Sim |
| T4 | Não | Não | Não | Não |
| T6 | Não | Não | Não | Não |
| T7 | Não | Sim | Sim | Sim |

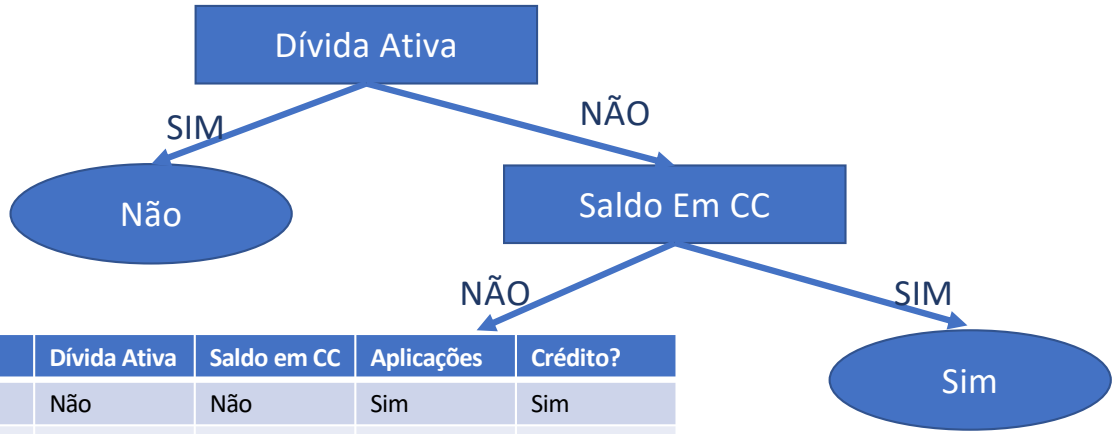
# Algoritmo de Indução




| Instância | Dívida Ativa | Saldo em CC | Aplicações | Crédito? |
|---|---|---|---|---|
| T2 | Não | Não | Sim | Sim |
| T4 | Não | Não | Não | Não |
| T6 | Não | Não | Não | Não |

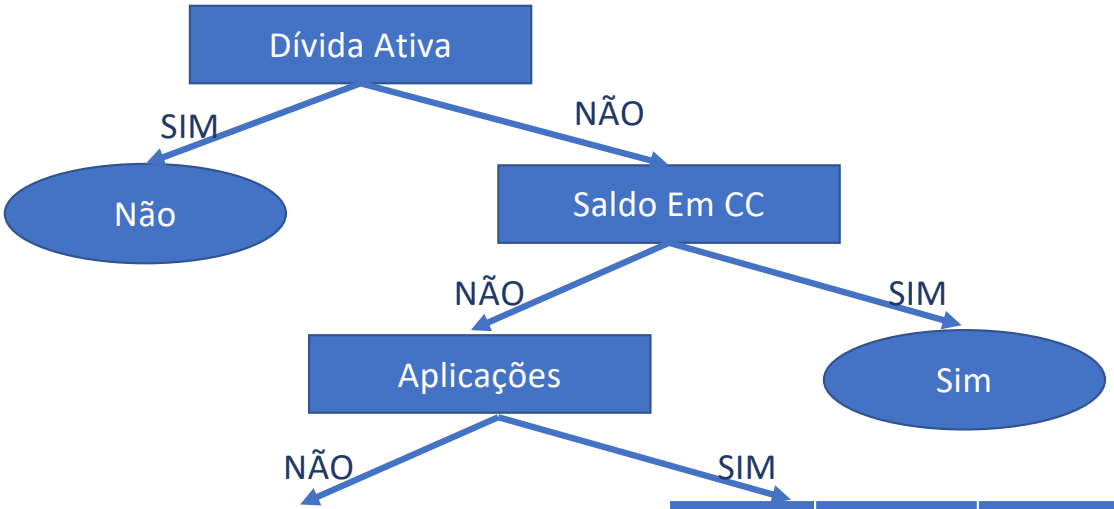
| Instância | Dívida Ativa | Saldo em CC | Aplicações | Crédito? |
|---|---|---|---|---|
| T3 | Não | Sim | Não | Sim |
| T7 | Não | Sim | Sim | Sim |

# Algoritmo de Indução




| Instância | Dívida Ativa | Saldo em CC | Aplicações | Crédito? |
|---|---|---|---|---|
| T2 | Não | Não | Sim | Sim |
| T4 | Não | Não | Não | Não |
| T6 | Não | Não | Não | Não |

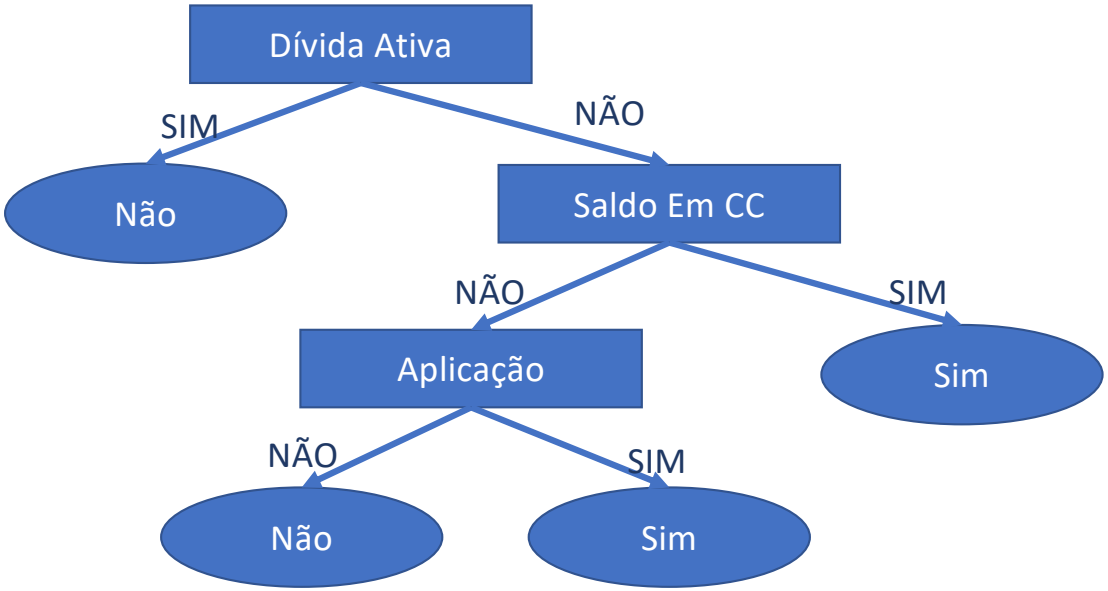
# Algoritmo de Indução




| Instância | Dívida Ativa | Saldo em CC | Aplicações | Crédito? |
|---|---|---|---|---|
| T4 | Não | Não | Não | Não |
| T6 | Não | Não | Não | Não |

| Instância | Dívida Ativa | Saldo em CC | Aplicações | Crédito? |
|---|---|---|---|---|
| T2 | Não | Não | Sim | Sim |

# Algoritmo de Indução



# Métrica de separabilidade

- Como selecionar o atributo mais adequado para dividir?
  - Deve ser selecionado o atributo que gere o subconjuntos mais puros possíveis de instâncias.

# Métrica de separabilidade

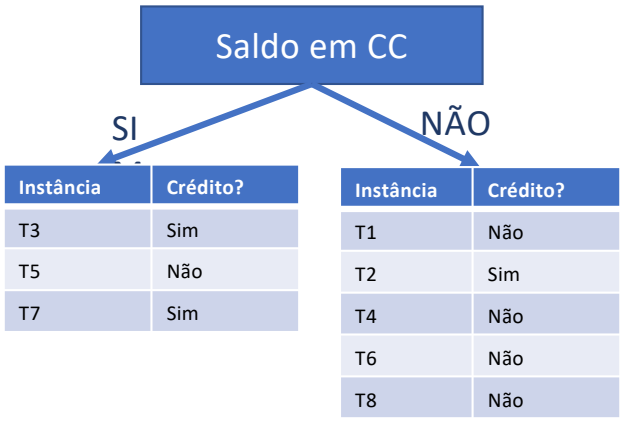
- Como selecionar o atributo para dividir?

| Instância | Dívida Ativa | Saldo em CC | Aplicações | Crédito? |
|---|---|---|---|---|
| T1 | Sim | Não | Sim | Não |
| T2 | Não | Não | Sim | Sim |
| T3 | Não | Sim | Não | Sim |
| T4 | Não | Não | Não | Não |
| T5 | Sim | Sim | Não | Não |
| T6 | Não | Não | Não | Não |
| T7 | Não | Sim | Sim | Sim |
| T8 | Sim | Não | Não | Não |



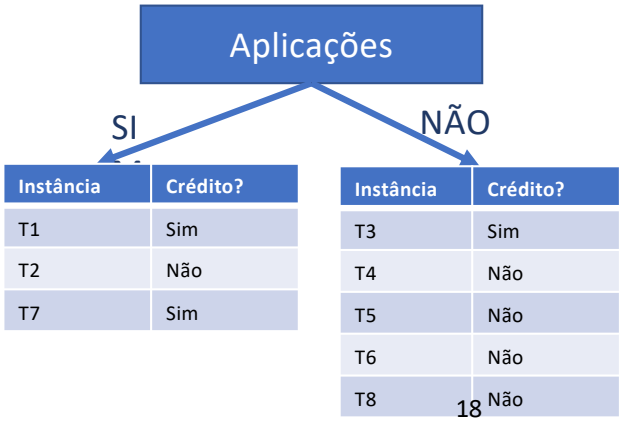

| Instância | Crédito? |
|---|---|
| T1 | Não |
| T5 | Não |
| T8 | Não |

| Instância | Crédito? |
|---|---|
| T2 | Sim |
| T3 | Sim |
| T4 | Não |
| T6 | Não |
| T7 | Sim |




| Instância | Crédito? |
|---|---|
| T3 | Sim |
| T5 | Não |
| T7 | Sim |

| Instância | Crédito? |
|---|---|
| T1 | Não |
| T2 | Sim |
| T4 | Não |
| T6 | Não |
| T8 | Não |




| Instância | Crédito? |
|---|---|
| T1 | Sim |
| T2 | Não |
| T7 | Sim |

| Instância | Crédito? |
|---|---|
| T3 | Sim |
| T4 | Não |
| T5 | Não |
| T6 | Não |
| T8 | Não |

# Métrica de separabilidade

- Como selecionar o atributo para dividir?

| Instância | Dívida Ativa | Saldo em CC | Aplicações | Crédito? |
|---|---|---|---|---|
| T1 | Sim | Não | Sim | Não |
| T2 | Não | Não | Sim | Sim |
| T3 | Não | Sim | Não | Sim |
| T4 | Não | Não | Não | Não |
| T5 | Sim | Sim | Não | Não |
| T6 | Não | Não | Não | Não |
| T7 | Não | Sim | Sim | Sim |
| T8 | Sim | Não | Não | Não |



# Métrica de separabilidade

- Métrica de entropia como medida de ordem/desordem dos dados.

- Dados organizados (com ordem):
  - Nó puro equivale a todas as instâncias da mesma classe;
  - Quando o nó é puro a entropia tem valor mínimo.

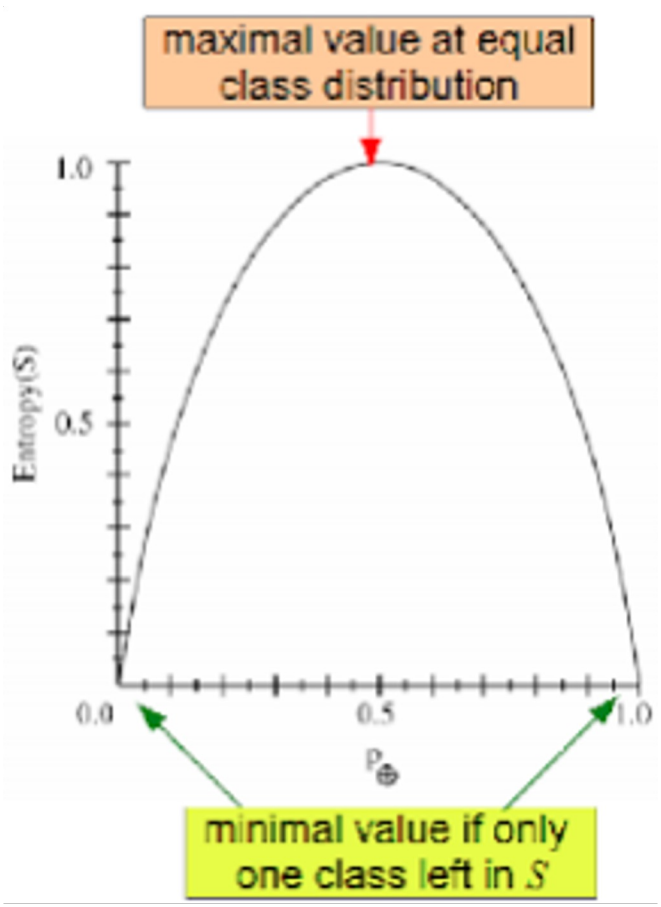
- Dados desorganizados (sem ordem):
  - Quando a impureza é máximo todas as classes possuem a mesma probabilidade;
  - Quando a impureza é máxima a entropia tem valor máximo.

# Métrica de separabilidade

- Entropia
  - Medida entre 0 e 1
  - Valor 0 representa um conjunto organizado
  - Valor 1 representa um conjunto desorganizado

$$H_p(p) = -\sum_{i=1}^{n} p_i * log_2(p_i)$$

$p_i$ é a probabilidade de uma instância ser da classe *i*



# Métrica de separabilidade – Entropia

- Como selecionar o atributo para dividir?

Entropia dos dados não separados:
3/8*log2(3/8) -5/8*log2(5/8)
0.95443

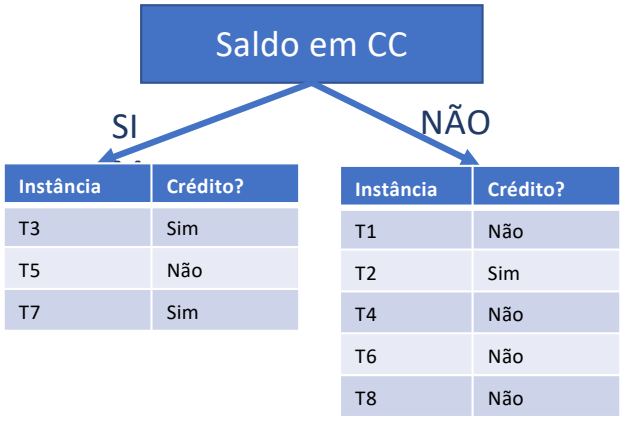



| Instância | Crédito? |
|---|---|
| T1 | Não |
| T5 | Não |
| T8 | Não |

| Instância | Crédito? |
|---|---|
| T2 | Sim |
| T3 | Sim |
| T4 | Não |
| T6 | Não |
| T7 | Sim |

-0/3*log2(0/3) -3/3*log2(3/3)
0.00000

-3/5*log2(3/5) -2/5*log2(2/5)
0.97095

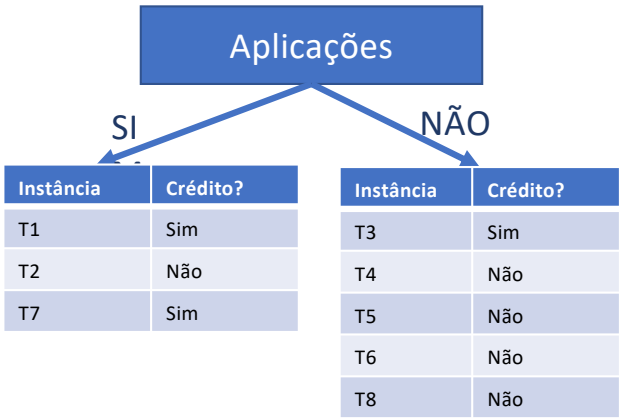



| Instância | Crédito? |
|---|---|
| T3 | Sim |
| T5 | Não |
| T7 | Sim |

| Instância | Crédito? |
|---|---|
| T1 | Não |
| T2 | Sim |
| T4 | Não |
| T6 | Não |
| T8 | Não |

-2/3*log2(2/3) -1/3*log2(1/3)
0.91829

-1/5*log2(1/5) -4/5*log2(4/5)
0.72192




| Instância | Crédito? |
|---|---|
| T1 | Sim |
| T2 | Não |
| T7 | Sim |

| Instância | Crédito? |
|---|---|
| T3 | Sim |
| T4 | Não |
| T5 | Não |
| T6 | Não |
| T8 | Não |

-2/3*log2(2/3) -1/3*log2(1/3)
0.91829

-1/5*log2(1/5) -4/5*log2(4/5)
0.72192

# Métrica de separabilidade – Entropia

- Entropia média do conjunto
  - A medida de entropia vista lida apenas com um subconjunto
  - Como avaliar a divisão como um todo?
  - Média ponderada com base no número de instâncias de cada conjunto

$$\sum_{A_{ij} \subset A_i} \frac{|S_{aij}|}{|S|} * Entropia(S_{aij})$$

# Métrica de separabilidade – Ganho de Informação

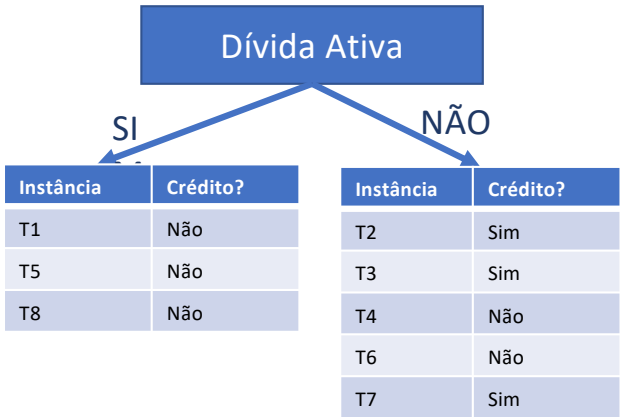
- Ganho de informação
  - O quão interessante é realizar a divisão?
  - Comparação da entropia antes e após a divisão
  - Maximizar o ganho de informação significa reduzir a entropia
  - Se não houver um ganho de informação mínimo não é interessante continuar a divisão

$$Ganho(S, A_i) = Entropia(S) - \sum_{A_{ij} \subset A_i} \frac{|S_{aij}|}{|S|} * Entropia(S_{aij})$$

# Métrica de separabilidade – Ganho de Informação

- Como selecionar o atributo para dividir?

Entropia dos dados não separados:
H=0.95443




| Instância | Crédito? |
|---|---|
| T1 | Não |
| T5 | Não |
| T8 | Não |

| Instância | Crédito? |
|---|---|
| T2 | Sim |
| T3 | Sim |
| T4 | Não |
| T6 | Não |
| T7 | Sim |

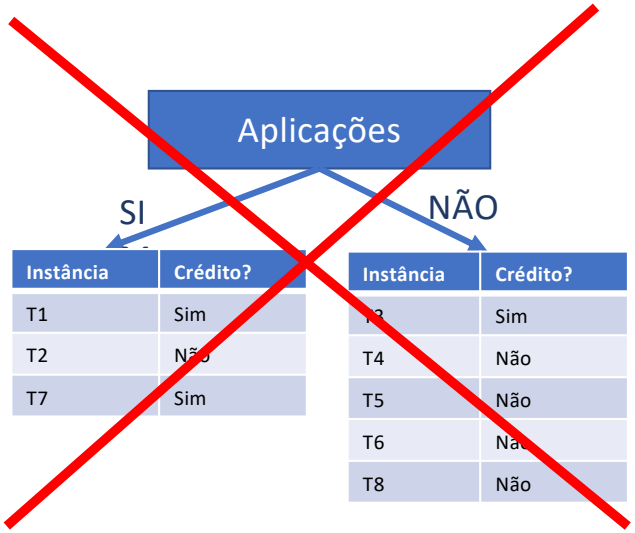
H=3/8 * 0.00000 + 5/8 * 0.97095
H=0.60684
Ganho= 0.95443 - 0.60684 = 0.34759




| Instância | Crédito? |
|---|---|
| T3 | Sim |
| T5 | Não |
| T7 | Sim |

| Instância | Crédito? |
|---|---|
| T1 | Não |
| T2 | Sim |
| T4 | Não |
| T6 | Não |
| T8 | Não |

H=3/8 * 0.91829 + 5/8 * 0.72192
H=0.79555
Ganho= 0.95443 - 0.79555 = 0.15888




| Instância | Crédito? |
|---|---|
| T1 | Sim |
| T2 | Não |
| T7 | Sim |

| Instância | Crédito? |
|---|---|
| T3 | Sim |
| T4 | Não |
| T5 | Não |
| T6 | Não |
| T8 | Não |

H=3/8 * 0.91829 + 5/8 * 0.72192
H=0.79555
Ganho= 0.95443 – 0.79555 = 0.15888

# Classificação de Atributos Contínuos

- São atributos que podem conter infinitos valores.
- Diferentemente de atributos nominais, os atributos numéricos tem muitas possibilidades de pontos de separação.
- O método mais utilizado é o de separação binária.
- A solução é avaliar o ganho de informação (ou qualquer outra métrica) para cada possível ponto de separação do atributo.
- A escolha deve ser o melhor ponto de separação.
- Nesse caso, o ganho de informação da melhor separação será o ganho de informação do atributo.
- A avaliação de atributos numéricos demanda mais esforço computacional.

# Classificação de Atributos Contínuos

- Assuma que a temperatura é um atributo contínuo
  - Ordene todos os registros de acordo com o valor do atributo.
  - Por exemplo:

| Valor: | 64 | 65 | 68 | 69 | 70 | 71 | 72 | 72 | 75 | 75 | 80 | 81 | 83 | 85 |
|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| Classe: | Yes | No | Yes | Yes | Yes | No | No | Yes | Yes | Yes | No | Yes | Yes | No |

  - Faça a separação entre cada par de valores:
    - E.g. Temperature $< 71.5$: yes/4, no/2
      Temperature $\geq 71.5$: yes/5, no/3

$$I(\text{Temperature} @ 71.5) = \frac{6}{14} \cdot E(\text{Temperature} < 71.5) + \frac{8}{14} E(\text{Temperature} \geq 71.5) = 0.939$$

  - O ponto de separação será posicionado entre os valores ou diretamente em um dos valores.

# Classificação de Atributos Contínuos

| Cheat | No | No | No | Yes | Yes | Yes | No | No | No | No |
|---|---|---|---|---|---|---|---|---|---|---|
| Taxable Income | | | | | | | | | | |
| Sorted Values → | 60 | 70 | 75 | 85 | 90 | 95 | 100 | 120 | 125 | 220 |
| Split Positions → | 55 | 65 | 72 | 80 | 87 | 92 | 97 | 110 | 122 | 172 | 230 |

| | <= | > | <= | > | <= | > | <= | > | <= | > | <= | > | <= | > | <= | > | <= | > | <= | > | <= | > |
|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| Yes | 0 | 3 | 0 | 3 | 0 | 3 | 0 | 3 | 1 | 2 | 2 | 1 | 3 | 0 | 3 | 0 | 3 | 0 | 3 | 0 | 3 | 0 |
| No | 0 | 7 | 1 | 6 | 2 | 5 | 3 | 4 | 3 | 4 | 3 | 4 | 3 | 4 | 4 | 3 | 5 | 2 | 6 | 1 | 7 | 0 |
| Gini | 0.420 | | 0.400 | | 0.375 | | 0.343 | | 0.417 | | 0.400 | | ***0.300*** | | 0.343 | | 0.375 | | 0.400 | | 0.420 | |

Valor escolhido por minimizar a Gini

# Regressão com Árvores de Decisão

- Em problemas de regressão, a função de custo a minimizar é, usualmente, o erro quadrático.
- Nesse caso, a média é a constante que minimiza o erro quadrático.
- Portanto, a constante associada às folhas de uma árvore de regressão é a **média dos valores do atributo alvo** dos exemplos de treinamento que caem na folha.
- Dessa forma, a construção de uma árvore de regressão é semelhante a uma árvore de classificação.

# Regressão com Árvores de Decisão

- Para estimar o mérito da separação por um determinado atributo, comumente é utilizada a métrica SDR (*Standard Deviation Reduction*)
- Para um conjunto de instâncias *D*, com *n* exemplos, a variância da variável alvo, y, é dada pela equação:

$$sd(\mathbf{D}, \mathbf{y}) = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \bar{y})^2}$$

- Considerando um teste hipotético $h_a$ sobre um atributo A, com A <= $a_1$, os exemplos do conjunto D são divididos em dois subconjuntos, $D_L$ e $D_R$, cuja redução da variância pode ser estimada por:

$$SDR(h_A) = sd(\mathbf{D}, \mathbf{y}) - \frac{n_L}{n} \times sd(\mathbf{D}_L, \mathbf{y}) - \frac{n_R}{n} \times sd(\mathbf{D}_R, \mathbf{y})$$

# Regressão com Árvores de Decisão

- Base de dados sobre quantidade de jogadores jogando golf baseado em formações da condição do tempo.
- Portanto, o atributo alvo (target) é o Golf Players.
- Por ser contínuo, deve aplicar uma regressão.

| Day | Outlook | Temp. | Humidity | Wind | Golf Players |
|---|---|---|---|---|---|
| 1 | Sunny | Hot | High | Weak | 25 |
| 2 | Sunny | Hot | High | Strong | 30 |
| 3 | Overcast | Hot | High | Weak | 46 |
| 4 | Rain | Mild | High | Weak | 45 |
| 5 | Rain | Cool | Normal | Weak | 52 |
| 6 | Rain | Cool | Normal | Strong | 23 |
| 7 | Overcast | Cool | Normal | Strong | 43 |
| 8 | Sunny | Mild | High | Weak | 35 |
| 9 | Sunny | Cool | Normal | Weak | 38 |
| | Rain | Mild | Normal | Weak | 46 |
| | Sunny | Mild | Normal | Strong | 48 |
| | Overcast | Mild | High | Strong | 52 |
| | Overcast | Hot | Normal | Weak | 44 |
| | Rain | Mild | High | Strong | 30 |

## Standard deviation

Golf players = {25, 30, 46, 45, 52, 23, 43, 35, 38, 46, 48, 52, 44, 30}

Average of golf players = (25 + 30 + 46 + 45 + 52 + 23 + 43 + 35 + 38 + 46 + 48 + 52 + 44 + 30 )/14 = 39.78

Standard deviation of golf players = $\sqrt{[( (25 - 39.78)^2 + (30 - 39.78)^2 + (46 - 39.78)^2 + \ldots + (30 - 39.78)^2 )/14]}$ = 9.32

# Regressão com Árvores de Decisão

- Teste do atributo Outlook.

**Summarizing standard deviations for the outlook feature**

| Outlook | Stdev of Golf Players | Instances |
|---|---|---|
| Overcast | 3.49 | 4 |
| Rain | 10.87 | 5 |
| Sunny | 7.78 | 5 |

Weighted standard deviation for outlook = (4/14)x3.49 + (5/14)x10.87 + (5/14)x7.78 = 7.66

Standard deviation reduction for outlook = 9.32 – 7.66 = 1.66

# Regressão com Árvores de Decisão

- Teste do atributo temperature.

**Summarizing standard deviations for temperature feature**

| Temperature | Stdev of Golf Players | Instances |
|---|---|---|
| Hot | 8.95 | 4 |
| Cool | 10.51 | 4 |
| Mild | 7.65 | 6 |

Weighted standard deviation for temperature = (4/14)x8.95 + (4/14)x10.51 + (6/14)x7.65 = 8.84

Standard deviation reduction for temperature = 9.32 – 8.84 = 0.47

# Regressão com Árvores de Decisão

- Teste do atributo humidity.

**Summarizing standard deviations for humidity feature**

| Humidity | Stdev of Golf Player | Instances |
|---|---|---|
| High | 9.36 | 7 |
| Normal | 8.73 | 7 |

Weighted standard deviation for humidity = (7/14)x9.36 + (7/14)x8.73 = 9.04

Standard deviation reduction for humidity = 9.32 – 9.04 = 0.27

# Regressão com Árvores de Decisão

- Teste do atributo wind.

**Summarizing standard deviations for wind feature**

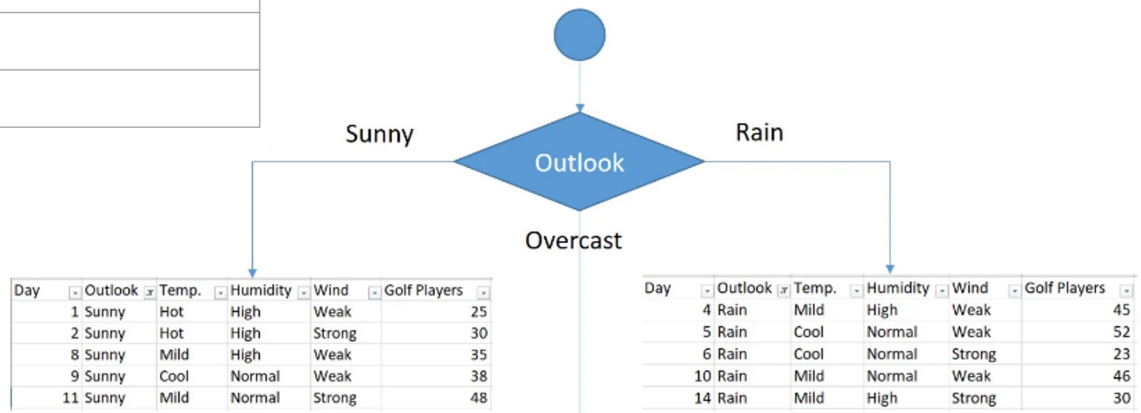
| Wind | Stdev of Golf Player | Instances |
|---|---|---|
| Strong | 10.59 | 6 |
| Weak | 7.87 | 8 |

Weighted standard deviation for wind = (6/14)x10.59 + (8/14)x7.87 = 9.03

Standard deviation reduction for wind = 9.32 – 9.03 = 0.29

# Regressão com Árvores de Decisão

| Feature | Standard Deviation Reduction |
|---|---|
| Outlook | 1.66 |
| Temperature | 0.47 |
| Humidity | 0.27 |
| Wind | 0.29 |




| Day | Outlook | Temp. | Humidity | Wind | Golf Players |
|---|---|---|---|---|---|
| 1 | Sunny | Hot | High | Weak | 25 |
| 2 | Sunny | Hot | High | Strong | 30 |
| 8 | Sunny | Mild | High | Weak | 35 |
| 9 | Sunny | Cool | Normal | Weak | 38 |
| 11 | Sunny | Mild | Normal | Strong | 48 |

| Day | Outlook | Temp. | Humidity | Wind | Golf Players |
|---|---|---|---|---|---|
| 4 | Rain | Mild | High | Weak | 45 |
| 5 | Rain | Cool | Normal | Weak | 52 |
| 6 | Rain | Cool | Normal | Strong | 23 |
| 10 | Rain | Mild | Normal | Weak | 46 |
| 14 | Rain | Mild | High | Strong | 30 |

| Day | Outlook | Temp. | Humidity | Wind | Golf Players |
|---|---|---|---|---|---|
| 3 | Overcast | Hot | High | Weak | 46 |
| 7 | Overcast | Cool | Normal | Strong | 43 |
| 12 | Overcast | Mild | High | Strong | 52 |
| 13 | Overcast | Hot | Normal | Weak | 44 |

Overcast já é um atributo puro

# Regressão com Árvores de Decisão

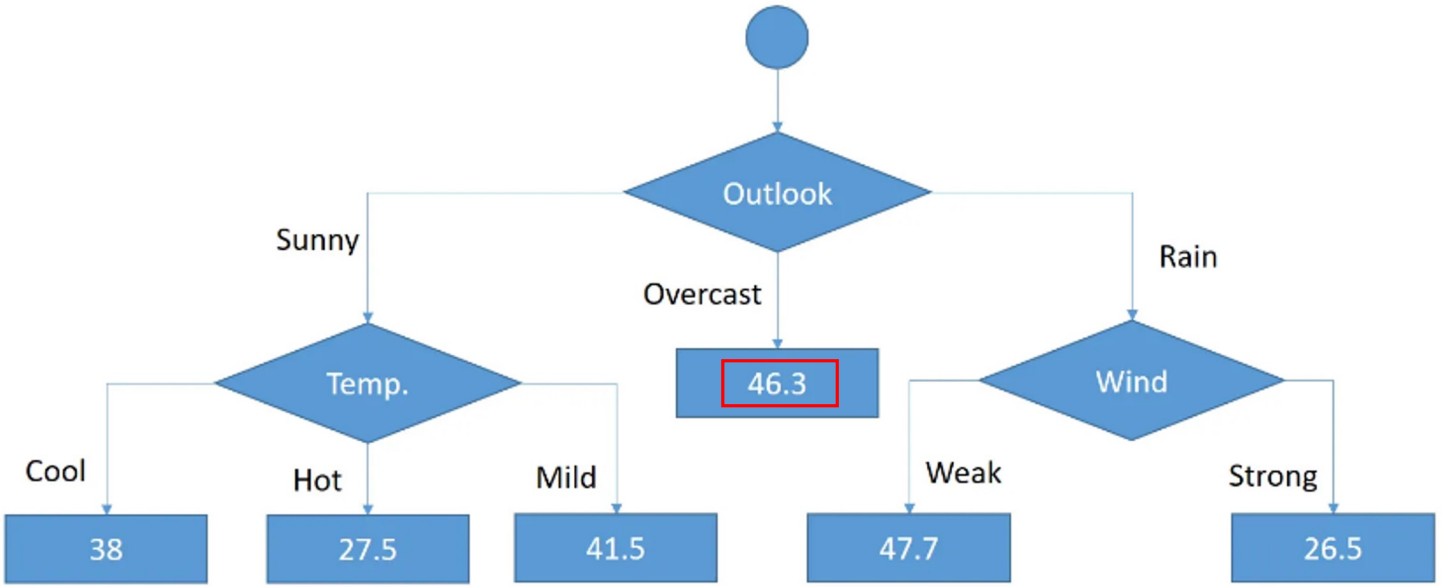
- Por ser puro, o nó Outlook com valor Overcast é um **nó folha**.
- Um nó folha representa a média dos valores do atributo alvo.

| Day | Outlook | Temp. | Humidity | Wind | Golf Players |
|---|---|---|---|---|---|
| 3 | Overcast | Hot | High | Weak | 46 |
| 7 | Overcast | Cool | Normal | Strong | 43 |
| 12 | Overcast | Mild | High | Strong | 52 |
| 13 | Overcast | Hot | Normal | Weak | 44 |

If outlook is overcast, then there would be (46+43+52+44)/4 = 46.25 golf players.

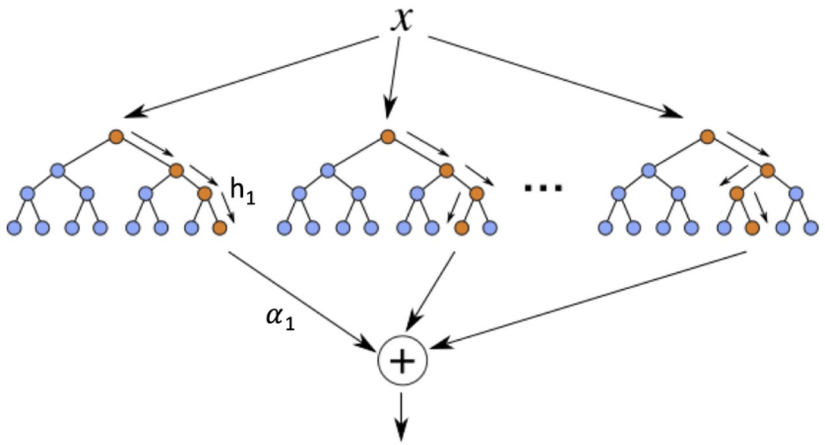
# Regressão com Árvores de Decisão

- Resultado final do processo de indução de uma árvore de regressão.



# Conjuntos de Árvores de Decisão

- Também chamados de *ensembles*, são ideais para reduzir o *overfitting* dos modelos, aumentando assim a precisão
- São construídos vários estimadores, usando o mesmo modelo várias vezes e o resultado final é calculado utilizando os resultados dos modelos individuais



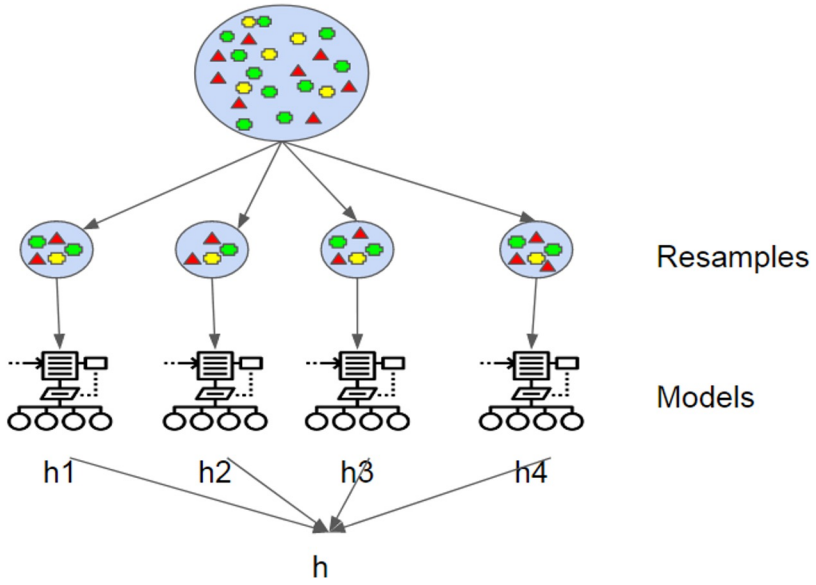
# Conjuntos de Árvores de Decisão

Regressão e classificação:

- Bagging
- Random Forest
  - Extremely Randomized Trees
- Boosting
  - Adaptive Booster
  - Gradient Boost
  - XGBoost

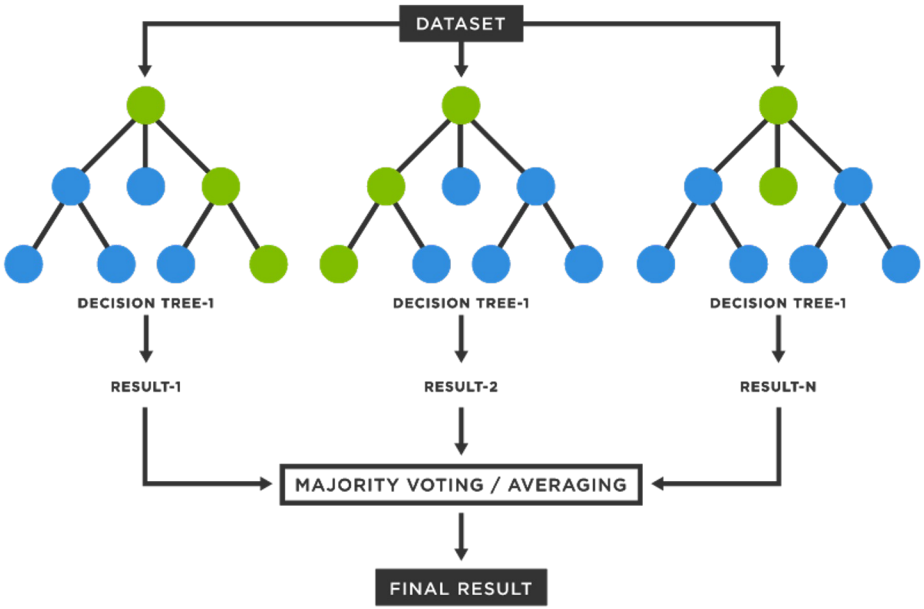
# Bagging

- Os modelos individuais são construídos com diferentes amostras
- Resultado final é calculado por média ou votação



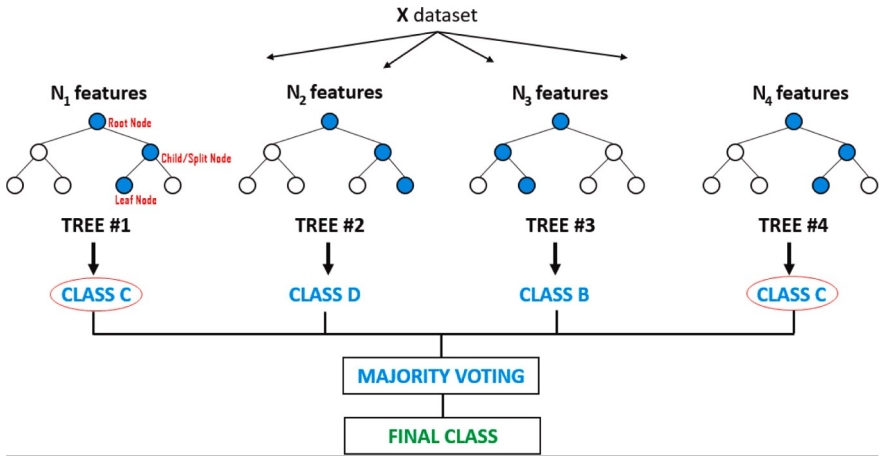
# Random Forest

- Os modelos individuais são construídos com diferentes amostras
- Na criação dos nós existe uma etapa aleatória de seleção de *features*



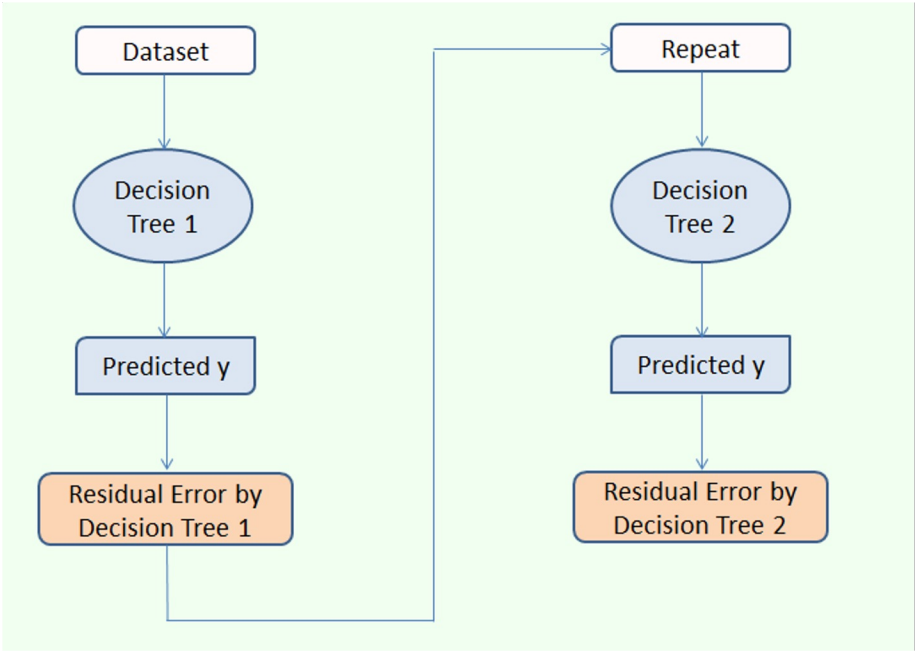
# Extremely Randomized Trees

- Similar ao Random Forest, mas com mais uma etapa aleatória
- Após a seleção aleatória das variáveis candidatas para o nó inicial, os dados existentes em cada uma destas variáveis serão separados (split dos dados) também de maneira aleatória



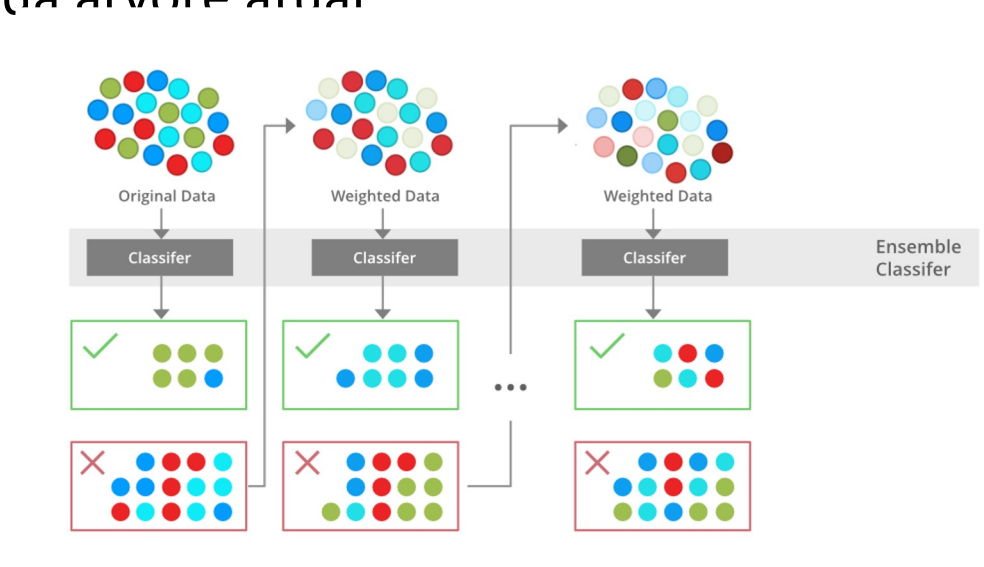
# Boosting

- Faz a construção do modelo em **etapas**, de forma iterativa
- Os novos modelos “fracos” são ajustados em favor das instâncias classificadas incorretamente pelos classificadores anteriores



# AdaBoost (Adaptive Boost)

- Utiliza o erro da árvore anterior para atribuir pesos às amostras de treinamento da árvore atual



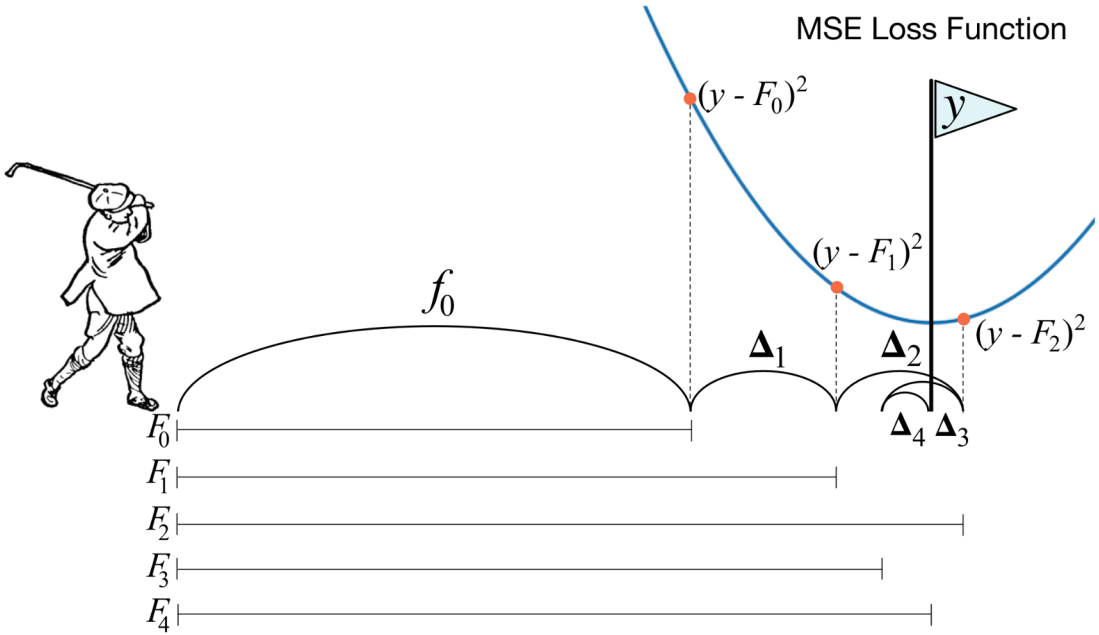
# Gradient Boost

- Várias árvores de decisão dando **pequenos passos** em direção à solução final
- Método do **gradiente** (método do máximo declive)
- **Otimização** da função de perda iterativamente

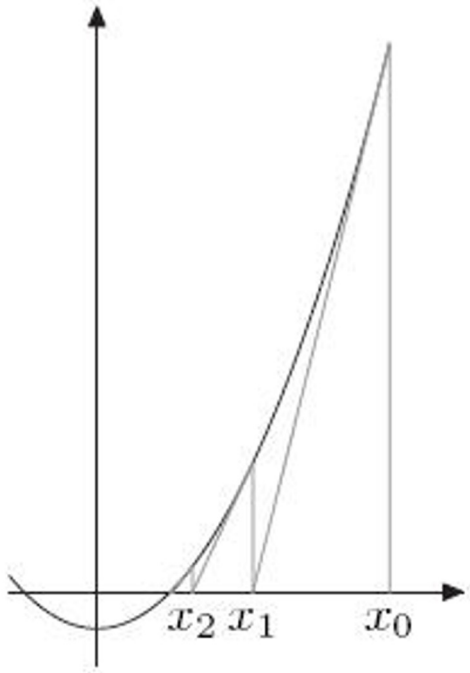
$$F_m(x) = F_{m-1}(x) + \nu \cdot \gamma_m h_m(x), \quad 0 < \nu \leq 1,$$

$$h_m(x) = -\frac{\partial L_{\text{MSE}}}{\partial F} = y - F(x).$$

$\gamma m$ = tamanho do passo



# XGBoost




- e**X**treme **G**radient **Boost**ing
- Derivada de **segunda** ordem, similar ao método de Newthon-Raphson
- Penalização de árvores
- Encolhimento de nós
- Parâmetro extra de aleatoriedade
- Implementação em multi-core
  - Paralelismo aplicado aos nós de mesma profundidade
- Seleção automática de características
- https://xgboost.readthedocs.io/en/stable/index.html

# Métodos de Validação

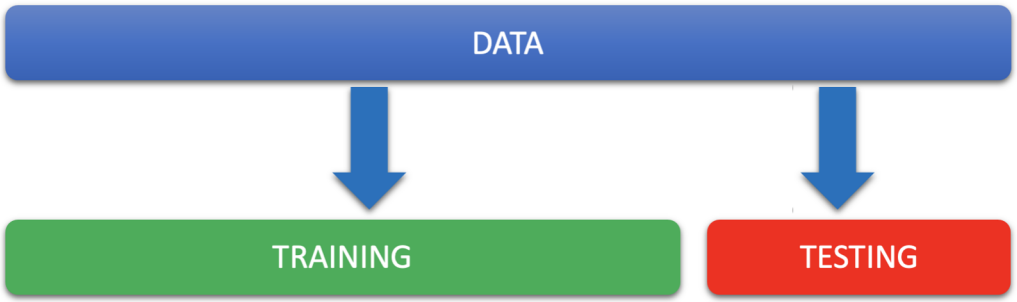
- Validação é o processo de garantir que o modelo seja bem generalizado
- Generalização é quando o modelo é construído usando um conjunto de dados e tem um bom desempenho em um conjunto de dados completamente diferente
- O conjunto de validação é aquele conjunto de dados no qual melhoramos o erro de generalização
- O conjunto de validação serve a dois propósitos.
  - É usado para ajustar "hiperparâmetros" do algoritmo de aprendizado de máquina
  - Ele serve como um conjunto de teste intermediário

# Métodos de Validação - Hiperparâmetros

- Cada modelo de aprendizado de máquina possui parâmetros e, adicionalmente, pode ter hiperparâmetros.
- Os hiperparâmetros são aqueles parâmetros que não podem ser aprendidos diretamente no processo de treinamento regular
- Esses parâmetros expressam propriedades de "nível superior" do modelo, como sua complexidade ou a rapidez com que ele deve aprender.
- Exemplos de hiperparâmetros:
  - Nível de profundidade da árvore, quantidade de atributos das instâncias são necessários, número de árvores do conjunto (*ensembles*)

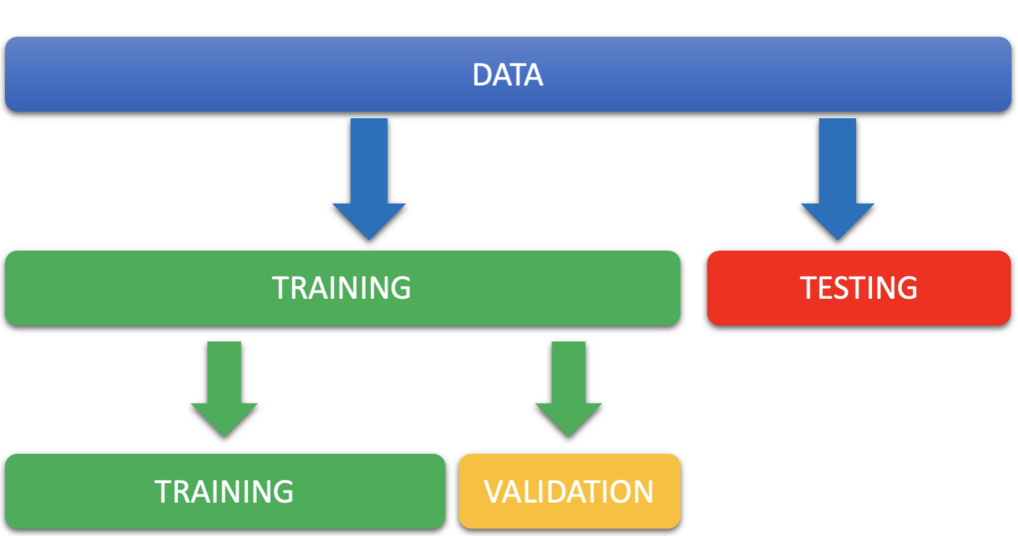
# Métodos de Validação

- A validação é o processo de ajuste dos hiperparâmetros feito com parte dos dados do conjunto de treinamento.
- Sem um conjunto de validação, a divisão de dados seria como ao lado.
- Sabendo que não se pode usar dados do conjunto de teste, precisa-se extrair dados do conjunto de treinamento para realizar a validação.
- Quanto mais dados de treinamento, melhor será a estimativa de parâmetro, mas quanto mais dados para validação, melhor será o ajuste dos hiperparâmetros.
- Com essa compensação em mente, temos algumas abordagens disponíveis para validação.



# Métodos de Validação – Hold-out

- Validação Hold-out é quando divide-se o conjunto de dados aleatoriamente em conjunto de treinamento e validação.
- Faz sentido coletar amostras aleatoriamente para os conjuntos de treinamento e validação, porque dessa forma não estás influenciando nenhum deles.
- Uma divisão comum é usar 80% dos dados para treinamento e os 20% restantes dos dados para validação.

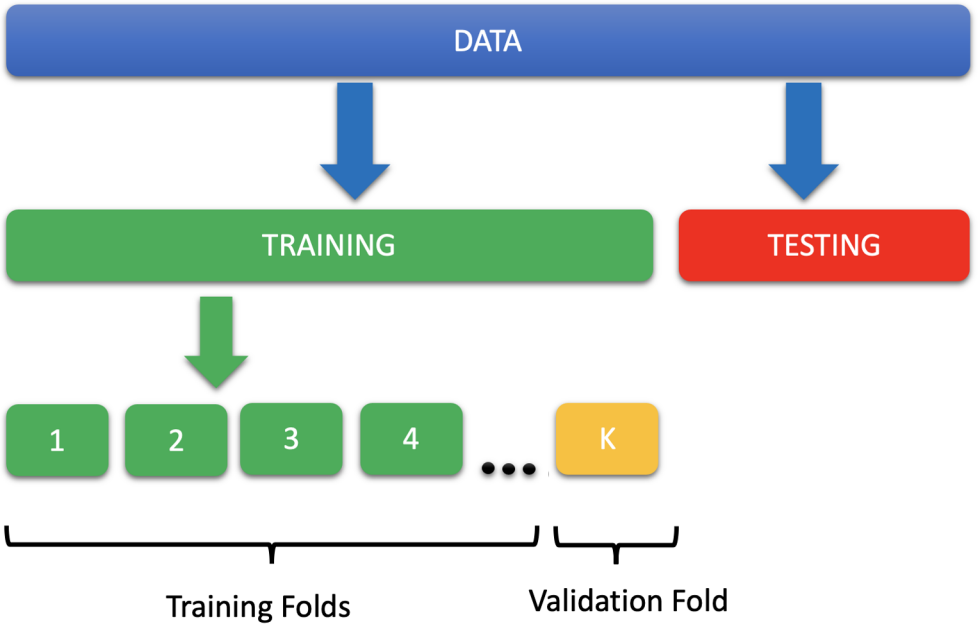


# Métodos de Validação – Hold-out

- Prós:
  - Dados totalmente independentes - Os dados que são separados do conjunto de treinamento tornam-se uma unidade totalmente independente. Nunca é tocado para fins de treinamento e, portanto, obtemos um bom conjunto para testes intermediários.
  - Na validação hold-out, realizamos o treinamento e a validação apenas uma vez. Esta é uma operação muito barata em comparação com o que faríamos na validação cruzada.
- Contras:
  - Não generaliza bem - a estimativa de validação do erro pode ser altamente variável, dependendo precisamente de quais observações estão incluídas no conjunto de treinamento e quais observações estão incluídas no conjunto de validação.

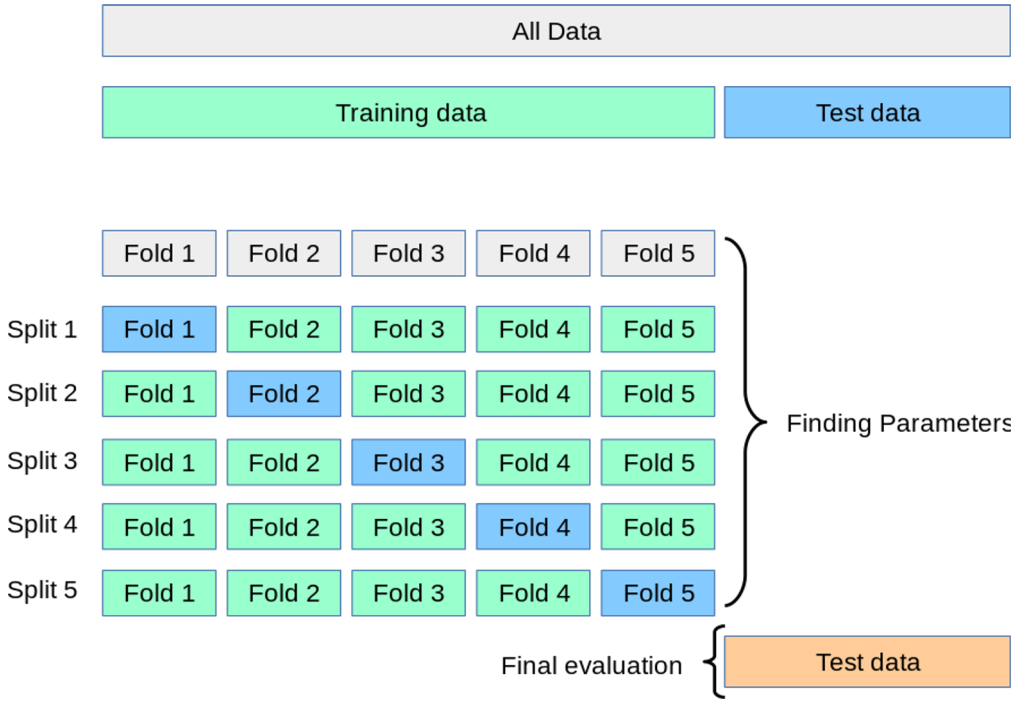
# Métodos de Validação – K-Fold Cross Validation

- Neste método os dados são divididos em K conjuntos chamados folds.
- Ela avalia todos os dados do do conjunto de treinamento, mas o faz dividindo o conjunto de treinamento em K folds (onde K é um número inteiro positivo).



# Métodos de Validação – K-Fold Cross Validation

- Ela treina o modelo K vezes, cada vez deixando um diferente fold de fora dos dados de treinamento e use-os como um conjunto de validação.
- Ao final, a métrica de desempenho (precisão, ROC, etc.) é calculada em todos os K testes.
- Assim que a melhor combinação de parâmetros for encontrada, o modelo é retreinado com todos os dados.



# Métodos de Validação – K-Fold Cross Validation

- Prós:
  - Livre de viés de seleção - Este método abrange todo o conjunto de treinamento e, portanto, não há viés de seleção no que diz respeito à divisão do conjunto de dados.
  - Generaliza bem.
  - Importa menos como os dados são divididos.
- Contras:
  - Alto custo computacional - O processo de treinamento é repetido K vezes, o que se torna muito demorado quando o conjunto de treinamento é muito grande, como no caso do Deep Learning.

# Métricas de Avaliação

- Uma métrica de avaliação quantifica o desempenho de um modelo preditivo.
- Isso envolve o treinamento de um modelo com um conjunto de dados e testá-lo em um conjunto de dados de validação não usado durante o treinamento, comparando as previsões aos valores esperados no conjunto de dados de validação.
- Para problemas de classificação, as métricas envolvem comparar o rótulo de classe esperado com o rótulo de classe previsto ou interpretar as probabilidades previstas para os rótulos de classe do problema.

# Métricas de Avaliação

- A classificação de uma instância do conjunto de validação, que portanto a classe já é conhecida, por um modelo preditivo terá um dois seguintes resultados:
  - **Positivos verdadeiros TP**: quando a classe real é positiva e a predita é positiva (atribuições positivas corretas),
  - **Negativos verdadeiros TN**: quando a classe real é negativa e a predita é negativa (atribuições negativas corretas),
  - **Positivos falsos FP**: quando a classe real é negativa e a predita é positiva (atribuições positivas incorretas) e
  - **Negativos falsos FN**: quando a classe real é positiva e a predita é negativa (atribuições negativas incorretas).

# Métricas de Avaliação

| | | True condition | | | | |
|---|---|---|---|---|---|---|
| | Total population | Condition positive | Condition negative | Prevalence = $\frac{\Sigma \text{ Condition positive}}{\Sigma \text{ Total population}}$ | Accuracy (ACC) = $\frac{\Sigma \text{ True positive} + \Sigma \text{ True negative}}{\Sigma \text{ Total population}}$ | |
| Predicted condition | Predicted condition positive | **True positive** | **False positive**, Type I error | Positive predictive value (PPV), Precision = $\frac{\Sigma \text{ True positive}}{\Sigma \text{ Predicted condition positive}}$ | False discovery rate (FDR) = $\frac{\Sigma \text{ False positive}}{\Sigma \text{ Predicted condition positive}}$ | |
| | Predicted condition negative | **False negative**, Type II error | **True negative** | False omission rate (FOR) = $\frac{\Sigma \text{ False negative}}{\Sigma \text{ Predicted condition negative}}$ | Negative predictive value (NPV) = $\frac{\Sigma \text{ True negative}}{\Sigma \text{ Predicted condition negative}}$ | |
| | | True positive rate (TPR), Recall, Sensitivity, probability of detection, Power = $\frac{\Sigma \text{ True positive}}{\Sigma \text{ Condition positive}}$ | False positive rate (FPR), Fall-out, probability of false alarm = $\frac{\Sigma \text{ False positive}}{\Sigma \text{ Condition negative}}$ | Positive likelihood ratio (LR+) = $\frac{\text{TPR}}{\text{FPR}}$ | Diagnostic odds ratio (DOR) = $\frac{\text{LR+}}{\text{LR−}}$ | $F_1$ score = $2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$ |
| | | False negative rate (FNR), Miss rate = $\frac{\Sigma \text{ False negative}}{\Sigma \text{ Condition positive}}$ | Specificity (SPC), Selectivity, True negative rate (TNR) = $\frac{\Sigma \text{ True negative}}{\Sigma \text{ Condition negative}}$ | Negative likelihood ratio (LR−) = $\frac{\text{FNR}}{\text{TNR}}$ | | |

# Proposta prática

- Notebooks

  Árvore de decisão - Classificação

  Árvore de decisão - Regressão